

TransE: Traslating Embeddings for Modeling Multi-relational Data

Domain	Graph
i≡ tag	Graph learning Low-dim vector space Vector embedding
© Conference / Journal	NeurlPs
≡ Publish year	2013
■ 정리 날짜	@2024년 1월 16일
≡ AI summary	TransE is a vector embedding model for knowledge graphs that focuses on energy efficiency and minimal parameters. It represents entities and relationships in a low-dimensional vector space and uses a distance-based energy framework for training. The model shows good performance and expressivity, outperforming previous methods in relational learning. However, it struggles with representing 3-way dependencies and interactions.
■ Al key info	TransE, Vector embedding, low-dim vector space, Knowledge graph, Graph learning, NeurlPs, 2013

Summary

knowledge graph를 vector embedding으로 구현 Energy efficiency에 초점 맞춰 적은 파라미터로 구현

Background

Multi-relational data

- Heterogeneous relationships
 - 。 다양한 특성의 edge들로 구성
- different type of relation, entity로 구성되기 때문에, 모델링하는데 더 generic한 approach 필요


Knowledge graph

• Entity 간의 relation을 나타낸 그래프

$$(h,l,t)$$
 -> head, label, tail

Translation

- 어떤 entity를 다른 entity로 매핑하는 relationship vector
- Embedding space에 translation을 나타냄



Motivation

기존 knowledge graph methods

• latent attribute로부터 relational learning하는 framework

- 문제점
 - 。 모델의 expressivity, universality 중시
 - complexity 높음 → high cost, 이해 어려움
 - o ovefitting: proper regularzation 어려움
 - underfitting: non-convex optimization problem

간단하고 좋은 성능의 모델 만들어보자

- multi-relational data를 low-dimensional vector space에 표현
 - o triplet당 low-dimensional vector가 하나인 embedding을 만들어보자
 - parameter set 크기 줄일 수 있음
 - t가 head + translation vector로 표현됨
 - 계층구조 relationship
 - 1 to 1 relationship : different type of relationship
- knowledge base model를 적은 데이터로 효율적으로 완성하는 tool 제공
- 이렇게 하는 기존 energy-based work들 성능 낫밷이더라

Methodology

vector embedding space

• t가 h+l로 표현되어, h+l과 가장 가까운 neighbor = t

$$h + \ell \approx t$$
 when (h, ℓ, t) holds

- energy-based framework에 기반
 - $\circ\;\;$ distance d(h+l,t): energy of a triplet: dissimilarity

Corrupted triplet

training triplet에서 head나 tail을 랜덤하게 바꿈

$$S'_{(h,\ell,t)} = \{(h',\ell,t)|h' \in E\} \cup \{(h,\ell,t')|t' \in E\}$$

기존 triplet의 distance와 비교하여 loss function 구하기 위함

Loss function

$$\mathcal{L} = \sum_{(h,\ell,t)\in S} \sum_{(h',\ell,t')\in S'_{(h,\ell,t)}} \left[\gamma + d(\boldsymbol{h} + \boldsymbol{\ell}, \boldsymbol{t}) - d(\boldsymbol{h'} + \boldsymbol{\ell}, \boldsymbol{t'}) \right]_{+}$$

 $[x]_+$ denotes the positive part of $x, \gamma > 0$ is a margin hyperparameter.

- corrupted triplet보다 energy 적은 training triplet을 학습
- SGD로 학습

Training algorithm

```
Algorithm 1 Learning TransE
```

```
input Training set S = \{(h, \ell, t)\}, entities and rel. sets E and L, margin \gamma, embeddings dim. k.

1: initialize \ell \leftarrow \text{uniform}(-\frac{6}{\sqrt{k}}, \frac{6}{\sqrt{k}}) for each \ell \in L
                          \ell \leftarrow \ell / \|\ell\| for each \ell \in L
e \leftarrow uniform(-\frac{6}{\sqrt{k}}, \frac{6}{\sqrt{k}}) for each entity e \in E
  2:
  3:
  4: loop
            \mathbf{e} \leftarrow \mathbf{e} / \|\mathbf{e}\| for each entity e \in E
  5:
             S_{batch} \leftarrow \text{sample}(S, b) \text{ // sample a minibatch of size } b
             T_{batch} \leftarrow \emptyset // initialize the set of pairs of triplets
  7:
            for (h, \ell, t) \in S_{batch} do
  8:
                 (h', \ell, t') \leftarrow \text{sample}(S'_{(h,\ell,t)}) \text{ // sample a corrupted triplet}
  9:
                 T_{batch} \leftarrow T_{batch} \cup \{((h, \ell, t), (h', \ell, t'))\}
10:
11:
                                                                                \sum \qquad \nabla \big[ \gamma + d(\boldsymbol{h} + \boldsymbol{\ell}, \boldsymbol{t}) - d(\boldsymbol{h'} + \boldsymbol{\ell}, \boldsymbol{t'}) \big]_+
             Update embeddings w.r.t.
12:
                                                                ((h,\ell,t),(h',\ell,t')) \in T_{batch}
13: end loop
```

- 시작
 - 각 entity와 relationship의 embedding 초기화
- Loop

- o triplet batch를 random sampling하여
- ∘ 각 triplet당 random corrupt를 만들어
- 。 이 각 non-corrupt, corrupt간 energy 차이로 학습 진행

Conclusion

Knowledge base를 minimal parameter로 학습

- energy efficient하지만, 좋은 성능
 - Expressivity가 SE에 비해 낫지만 성능은 더 좋음
 - relational propertie에 더 직접적으로 접근하기 때문에
 - Embedding model에서 최적화가 어렵기 때문에
 - 。 더 expressible하다는 게 더 나은 성능이 아니라 underfitting에 가까움
- Scailable

단점

- 2 way interaction을 표현하기 어려움
 - 。 1-to-many, many-to-many 같은 3-way dependency가 큰 경우 거의 실패함

Questions